

INT104 Tutorial 全部文件知识点总结

根据当前文件夹内 Lecture / Tutorial 2-11 PDF 整理。按考试复习逻辑组织：概念、公式、常见考法、易错点。

总览：全部文件的知识路线

统计基础 -> 概率分布 -> 参数估计与假设检验 -> 贝叶斯与 Naive Bayes -> 相关与回归 -> SVM -> kNN / 决策树 -> 模型评估 -> 多媒体 AI -> AI 伦理、安全与未来发展。

最容易考计算的是 Lecture 3-9；最容易考概念匹配的是 Lecture 2、10、11。

Lecture 2: Data and Statistics

Population, Sample, Parameter, Statistic

- Population 是研究对象总体；Sample 是从总体中抽出的部分。
- Parameter 描述总体，例如总体均值；Statistic 描述样本，例如样本均值。
- 记忆方式：Population -> Parameter；Sample -> Statistic。

Variable Types

- Categorical variable 是类别变量，例如专业、性别、类别标签。
- Quantitative variable 是数值变量，分为 discrete 和 continuous。
- Discrete 是可数的整数型数量，如次数、人数、quiz score；continuous 是连续测量值，如时间、身高、重量。

Sampling Bias

- 样本大不代表无偏，关键是样本是否能代表总体。
- Convenience sampling: 找最容易接触的人。
- Voluntary response sampling: 自愿填写问卷，常见于群聊发链接。
- Systematic sampling: 每隔固定间隔抽一个，如每第 8 个学生。
- Stratified sampling: 先分层，再在每层抽样，如按年级分层。
- Cluster sampling: 随机抽几个群体，再调查群体内所有成员。

Missing Data, Histogram, Skewness, Boxplot

- Delete cases 简单直接，但可能丢失信息；Impute missing values 保留样本，但可能扭曲结果。
- Histogram 用于显示数据分布形状；bins 太少会掩盖细节，bins 太多会突出噪声。
- Right-skewed distribution 右尾更长，通常 $\text{mean} > \text{median} > \text{mode}$ 。
- Boxplot 中 $\text{IQR} = Q3 - Q1$ ，中间 50% 的数据位于 $[Q1, Q3]$ 。

相关是否显著：比较 $|r|$ 和 critical value。

例： $r = 0.591$, critical value = ± 0.878 。

因为 $|0.591| < 0.878$ ，所以相关不显著。

Lecture 3: Data Distributions

Probability Basics

- Conditional probability: 在一个事件已发生的条件下，另一个事件发生的概率。
- Joint probability: 两个事件同时发生的概率。
- Probability distribution 是对不确定性的数学模型。

Common Distributions

- Binomial distribution: 固定 n 次试验，每次只有成功/失败。 n 是试验次数， x 是成功次数， p 是成功概率， $q = 1 - p$ 。
- Poisson distribution: 单位时间或单位空间内事件发生次数。 μ 表示平均发生次数。
- Normal distribution: 又叫 Gaussian distribution，钟形、对称。 μ 是均值， σ 是标准差。
- GMM: 用多个 Gaussian distributions 混合拟合复杂或多峰数据。

Z-score and CLT

$$z = (x - \mu) / \sigma$$

$x > \mu$ 时 z 为正； $x = \mu$ 时 $z = 0$ ； $x < \mu$ 时 z 为负。

Central Limit Theorem:

当样本量足够大，通常 $n > 30$ ，样本均值 $\bar{x}$ 的分布近似正态。

$$\text{mean}(\bar{x}) = \mu$$

$$\text{standard deviation}(\bar{x}) = \sigma / \sqrt{n}$$

GMM and EM

- Covariance matrix 描述变量方差和变量之间协方差。
- Mixture weights π_i 的总和为 1。
- EM algorithm 常用于估计 GMM 参数。

Lecture 4: Parameter Estimation & Hypothesis Testing

Estimation and Confidence Interval

- Point estimate: 用单个样本统计量估计总体参数。
- Confidence interval: 给出总体参数的 plausible range。
- 95% confidence 的正确理解: 长期重复抽样时，95% 的这种方法生成的区间会包含真实参数。

95% confidence level:

$$\alpha = 0.05$$

$$\alpha/2 = 0.025$$

$$1 - \alpha/2 = 0.975$$

Hypothesis Testing

- H_0 是 null hypothesis，通常表示无差异、无效果、等于某个值。
- H_a/H_1 是 alternative hypothesis，表示研究者想支持的方向。

- p-value 是在 H_0 为真时，得到当前或更极端结果的概率。

Decision rule:

```
if p-value <= alpha: reject H0
if p-value > alpha: fail to reject H0
```

Test Direction and Distribution

- $H_a: \mu > \mu_0$, 是 right-tailed test。
- $H_a: \mu < \mu_0$, 是 left-tailed test。
- $H_a: \mu \neq \mu_0$, 是 two-tailed test。
- 总体均值: z-test 或 t-test; 总体方差: chi-square; 多组均值比较: ANOVA; 不满足参数检验假设时: non-parametric tests。

Lecture 5: Counting Theories & Naive Bayes

Bayes Rule

```
P(c|x) = P(c)P(x|c) / P(x)
P(c): prior probability
P(x|c): likelihood
P(c|x): posterior probability
P(x): evidence
```

Likelihood, MLE, MAP

- Likelihood: 给定模型或参数时，观察到当前数据的概率。
- Log-likelihood: 把概率乘法变成加法，避免很多小概率相乘导致数值下溢。
- MLE: 选择让观察数据概率最大的参数。硬币例子中 $\theta_{MLE} = \text{heads} / \text{total tosses}$ 。
- MAP: 选择 posterior 最大的参数或模型，结合 likelihood 和 prior。

MLE 只看 likelihood。

MAP proportional to likelihood * prior。

Occam, Entropy, KL, Laplacian

- Occam Razor / Size Principle: 若两个假设都能解释数据，更小、更具体的假设可能更有力。
- Entropy 衡量不确定性，越混乱越高，越纯净越低。
- Cross entropy 衡量用一个分布编码另一个分布的代价。
- KL divergence 衡量两个分布之间的差异。

```
Entropy: H(p) = - sum p(x) log p(x)
KL(p||q) = sum p(x) log(p(x)/q(x))
Laplacian correction: P = (count + 1) / (total + number_of_classes)
```

Naive Bayes and Bayesian Network

$P(c|x_1, \dots, x_n)$ proportional to $P(c) P(x_1|c) P(x_2|c) \dots P(x_n|c)$

- Naive Bayes 的核心假设是特征之间条件独立。
- Bayesian Network 使用 DAG 表示变量依赖，把联合概率分解为条件概率乘积。

Lecture 6: Correlation and Regression

Pearson Correlation

- Pearson correlation coefficient r 衡量两个连续变量之间线性关系强弱。
- r 的范围是 -1 到 1 。 $r=1$ 完全正线性， $r=-1$ 完全负线性， $r=0$ 表示无线性相关。
- 单个 outlier 可能显著改变 correlation 和 regression line。
- 高相关不能证明因果，可能存在 confounder。

如果 $|r| > \text{critical value}$ ，则相关显著；否则不显著。

Linear Regression and Residual

Regression line: $y_{\text{hat}} = b_0 + b_1 x$
Slope: $b_1 = r * s_y / s_x$
Intercept: $b_0 = y_{\text{bar}} - b_1 * x_{\text{bar}}$
Residual = observed y - predicted y_{hat}

- Residual > 0 表示点在回归线上方；Residual < 0 表示点在回归线下方。

Regression Forms and Logistic Regression

- Linear: $y = a + bx$ 。
- Logarithmic: $y = a + b \ln x$ 。
- Power: $y = a x^b$ 。
- Quadratic: $y = ax^2 + bx + c$ 。
- Exponential: $y = ab^x$ 。

$P(Y=1) = 1 / (1 + e^{(-z)})$
 $z = \text{beta}_0 + \text{beta}_1 X_1 + \dots + \text{beta}_p X_p$
当 $z = 0$ 时， $P(Y=1) = 0.5$ 。常用于二分类。

Lecture 7: Support Vector Machine

Hyperplane, Distance, Margin

Hyperplane: $H = \{x : w^T x + b = 0\}$
Signed distance: $\text{dist}(x, H) = (w^T x + b) / ||w||$
Geometric margin: $\gamma_i = y_i (w^T x_i + b) / ||w||$
Dataset margin: $\gamma = \min_i \gamma_i$

- signed distance 的正负号表示点在超平面的哪一侧。

- $\text{sign}(w^T x + b)$ 对正比例缩放不敏感，所以 SVM 需要 normalization。

Hard-margin SVM

```
minimize 1/2 ||w||^2
subject to  $y_i(w^T x_i + b) \geq 1$  for all  $i$ 
```

Supporting hyperplanes:

$$w^T x + b = 1$$

$$w^T x + b = -1$$

$$\text{Margin width} = 2 / ||w||$$

Dual, KKT, Soft-margin, Kernel

Stationarity:

$$w = \sum_i \alpha_i y_i x_i$$

$$\sum_i \alpha_i y_i = 0$$

KKT complementary slackness:

$$\alpha_i (1 - y_i(w^T x_i + b)) = 0$$

Soft-margin:

$$y_i(w^T x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0$$

Kernel SVM:

$$f(x) = \sum_{i \in S} \alpha_i y_i K(x_i, x) + b$$

$$\hat{y} = \text{sign}(f(x))$$

- Support vectors 通常位于 margin 上，对决策边界有直接影响。
- $\xi_i = 0$ 表示正确且在 margin 外； $0 < \xi_i \leq 1$ 表示正确但进入 margin； $\xi_i > 1$ 表示分类错误。

Lecture 8: Non-parametric Learning

Non-parametric Models and kNN

- Non-parametric models 不预设固定形式的底层分布，适合复杂、多峰、不规则数据。
- 优点是灵活；缺点是常常需要更多数据，计算成本较高。
- kNN 对新样本寻找最近的 k 个训练样本，分类时使用 majority vote。
- k 太小容易受噪声影响； k 太大可能过度平滑、欠拟合。
- kNN 非常依赖距离度量，常见是 Euclidean distance。

Decision Tree

- 内部节点按属性划分，叶节点输出预测。
- 分类树输出类别；回归树输出数值，常为叶节点样本均值。
- 停止条件可以是节点纯净、无可属性、样本太少或达到最大深度。

Entropy, Gain, Gain Ratio

$\text{Entropy}(D) = - \sum_k p_k \log_2(p_k)$
 $\text{Gain}(D, x_j) = \text{Entropy}(D) - \text{weighted entropy after split}$
 $\text{GainRatio}(D, x_j) = \text{Gain}(D, x_j) / \text{IV}(a)$

- Entropy 越高，节点越混乱；Information gain 越大，划分后不确定性下降越多。
- Gain ratio 修正 information gain 偏好取值多属性的问题。

Lecture 9: Performance Evaluation

Confusion Matrix and Metrics

- TP: 预测 positive, 实际 positive。
- FP: 预测 positive, 实际 negative。
- FN: 预测 negative, 实际 positive。
- TN: 预测 negative, 实际 negative。

$\text{Accuracy} = (\text{TP} + \text{TN}) / (\text{TP} + \text{TN} + \text{FP} + \text{FN})$
 $\text{Recall} / \text{Sensitivity} / \text{TPR} = \text{TP} / (\text{TP} + \text{FN})$
 $\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$
 $\text{Specificity} / \text{TNR} = \text{TN} / (\text{TN} + \text{FP})$
 $\text{FPR} / \text{Fall-out} = \text{FP} / (\text{FP} + \text{TN})$
 $\text{FNR} / \text{Miss rate} = \text{FN} / (\text{TP} + \text{FN})$

 $\text{Recall} + \text{Miss} = 1$
 $\text{Specificity} + \text{Fall-out} = 1$

 $\text{F1} = 2 * \text{Precision} * \text{Recall} / (\text{Precision} + \text{Recall})$
 $\text{F1} = 2\text{TP} / (2\text{TP} + \text{FP} + \text{FN})$

Threshold, ROC, AUC

- Score-based classifier 通过阈值 tau 决定 positive 或 negative。
- 阈值升高通常更保守，FP 可能减少，但 FN 可能增加。
- ROC 横轴是 FPR，纵轴是 TPR。不同阈值对应 ROC 上不同点。
- AUC 是 ROC 曲线下面积。AUC=1 完美，AUC=0.5 接近随机猜测。

Cross-validation and Model Selection

- Hold-out: 划分训练集和测试集。
- Bootstrap: 有放回抽样。
- k-fold: 分成 k 折，轮流用一折测试，其余训练。
- Leave-one-out: k 等于样本数。
- Validation set 用于模型选择和调参；test set 用于最终评估。用 test set 调参会造成 data leakage。
- AIC/BIC 用于模型选择，兼顾拟合效果和模型复杂度，一般越小越好。

Lecture 10: AI Systems, Vision, Audio, NLP, Multimodal AI

AI System Pipeline

Formulate Problem -> Collect Data -> Feature Extraction -> Machine Learning -> System Deployed

Computer Vision

- Object detection / recognition: 自动驾驶识别车辆、行人。
- Image segmentation: 医学图像中划分肿瘤边界。
- Motion analysis: 监控系统追踪运动。
- Scene understanding: 理解图像并回答问题。
- Haar cascades 是传统方法; CNN 和 ViT 属于深度学习视觉方法。
- OpenCV 常用于视觉处理; MMDetection 常用于目标检测。

Audio and NLP

- MFCCs: 语音特征提取。
- HMMs: 传统序列音频建模。
- NMF: source separation。
- RNN/LSTM: 处理语音时序依赖。
- Transformer / Whisper: 现代多语言 ASR。
- Diffusion models: 高质量音频生成。
- Syntax-level NLP: tokenization, POS tagging, dependency parsing。
- Semantic-level NLP: NER, sentiment analysis, machine translation, summarization。
- Traditional NLP: Bag-of-Words, TF-IDF。
- Deep NLP: RNN, LSTM, Transformer, BERT, GPT。

Multimodal AI

Multimodal Input -> Feature Extraction -> Text/Audio/Visual Features -> Fusion Layer -> Decision Output

- 核心挑战包括 cross-modal alignment、feature fusion、context-aware interpretation。

Lecture 11: AI Ethics and Future Development

AI Lifecycle and Ethics

Formulate Problem -> Collect Data -> Feature Extraction -> Machine Learning -> System Deployed

如果部署后效果不好, 可以 refine features 或 collect new data。

- Data privacy: Anonymisation / federated learning。
- Data collection bias: Know your population。
- False media / deepfake: Deepfake detection。
- Power consumption: Algorithm simplification。

Federated Learning, Bias, Domain Shift

- Federated learning 让数据留在本地，减少集中传输带来的隐私泄露风险。
- 风险是本地数据分布、质量、特征定义可能不一致。
- 训练数据永远只能近似真实世界 ground truth distribution，不能完全等于它。
- Domain adaptation: 从 source domain 学习，并适应 target domain 的分布变化。
- Domain generalisation: 不直接调目标域，也希望在 unseen domains 表现好。
- Transfer learning: 把一个任务或领域学到的知识迁移到另一个任务或领域。

Algorithm Bias, Evaluation Bias, Security

- GMM 假设 cluster 可由 Gaussian distributions 近似。
- SVM 假设存在某个特征空间可用线性边界分类。
- Naive Bayes 假设因素之间条件独立。
- Accuracy 看总体正确率; Precision 重视减少 false positives; Recall 重视减少 false negatives。
- Euclidean distance 衡量绝对距离; Cosine distance 衡量方向差异; Correlation distance 衡量变化趋势差异。
- Perturbation: 测试阶段加入微小扰动让模型误判。
- Data poisoning: 训练集中注入恶意样本破坏模型。

Energy example:

$60 / 0.0005 = 120000$

含义: AlphaGo 约消耗人类参考能量的 120000 倍。AI 系统也要考虑能耗与可持续性。

最后背诵清单

- Lecture 2: 抽样方法、变量类型、偏态、IQR、相关显著性。
- Lecture 3: Binomial、Poisson、Normal、z-score、CLT、GMM。
- Lecture 4: confidence interval、alpha、p-value、H0/Ha、单尾/双尾。
- Lecture 5: Bayes rule、likelihood、MLE/MAP、entropy、KL、Laplacian、Naive Bayes。
- Lecture 6: correlation、critical r、regression line、residual、logistic regression。
- Lecture 7: SVM hyperplane、margin、primal、dual、KKT、soft-margin、kernel。
- Lecture 8: kNN、decision tree、entropy、information gain、gain ratio。
- Lecture 9: TP/FP/FN/TN、Accuracy、Precision、Recall、Specificity、F1、ROC、AUC、CV。
- Lecture 10: AI pipeline、CV/audio/NLP/multimodal tasks。
- Lecture 11: privacy、bias、domain shift、algorithm assumptions、security、energy。