

# INT104 人工智能

大题专项突破 + 历年真题解析

非选择题全部题型 (2020-2025真题)

基于历年全部试卷整理，覆盖kNN、朴素贝叶斯、K-means、感知机证明、层次聚类、Python编程、统计学新增题型

西交利物浦大学 INT104 期末备考

# 1. kNN 计算与交叉验证

---

## 核心概念 Core Concepts

City Block (Manhattan) 距离:  $d = |x_1 - x_2| + |y_1 - y_2|$  (多维则累加)

City Block距离 = 曼哈顿距离, 即各维度绝对差之和, 与欧几里得距离不同

k值选择: k太小 → 对噪声敏感; k太大 → 决策边界模糊; 最佳k通过交叉验证确定

k太小: 模型复杂, 易过拟合; k太大: 模型过于简单, 易欠拟合

打破平局 (Tie-breaking): 使用最小特征值 (如最小湿度) 作为决胜依据

特征加权 (Feature weighting): 对重要特征在距离计算中乘以权重  $w > 1$

## 标准解题步骤 Standard Solution Steps

1. 编码分类变量 (Encode categorical variables)  
Outlook: Sunny=0, Rainy=1; Preference: Yes=1, No=0
2. 计算测试点到所有训练点的 City Block 距离
3. 按距离排序, 取最近的 k 个邻居
4. 投票决定类别 (多数表决, majority vote)
5. 交叉验证: 对每个折重复上述步骤, 计算平均准确率

### [Exam 2022-2023 Final] Q4 (10分)

$k=3$ , City Block距离。测试点: (Sunny, 65%, 3.0m/s)。预测是否打高尔夫。

Answer: 预测: NO (不打高尔夫)

Analysis: 3个最近邻全为NO: S(70,5.0)  $d=7$ , R(75,4.0)  $d=12$ , S(75,0.4)  $d=12.6$  → 全部预测NO

### [Exam 2022-2023 Resit] Q4 (16分)

分别用 $k=1, k=2, k=5$ 预测同一点。哪个k最好?

Answer: 三者均预测NO; 最佳k需通过交叉验证确定

Analysis:  $k=1$ : 对异常值敏感;  $k=5$ : 对噪声更鲁棒。最佳k必须在训练数据上通过交叉验证选出, 不能主观判断。

### [Exam 2025 Sample] Q32 (15分)

12个样本, 3折交叉验证, 1-NN, City Block距离。折固定为{1-4},{5-8},{9-12}。

Answer: 计算每折准确率, 再取平均值

Analysis: 每折: 用其余8个样本训练, 对4个测试样本用1-NN预测。展示每个预测的最近邻样本ID和距离。

## 2. 朴素贝叶斯 (Naive Bayes) 完整计算

### 核心公式 Core Formula

贝叶斯定理 (Bayes Theorem) :  $P(A|B) = P(B|A) * P(A) / P(B)$

朴素假设 (Naive Assumption) : 各类特征在给定类别下条件独立

即:  $P(x_1, x_2, \dots, x_n | \text{class}) = P(x_1 | \text{class}) * P(x_2 | \text{class}) * \dots * P(x_n | \text{class})$

拉普拉斯平滑 (Laplacian Smoothing) :  $P(x|y) = (\text{count} + 1) / (\text{total} + \text{num\_categories})$

❗ 必须使用拉普拉斯平滑! 否则零计数 → 条件概率为0 → 整个后验概率为0!

### 标准解题步骤 Standard Solution Steps

1. 计算先验概率 (Prior) :  $P(l=0), P(l=1)$

2. 用拉普拉斯平滑计算各特征的条件概率

$P(x_i|l) = (\text{该特征在类别}l\text{中出现的次数} + 1) / (\text{类别}l\text{的总样本数} + \text{该特征可能的取值个数})$

3. 计算后验概率 (Posterior) :  $P(l|x)$  正比于  $P(l) * \text{所有} P(x_i|l) \text{的乘积}$

(建议取对数避免下溢:  $\log(P(l|x)) = \log(P(l)) + \sum(\log(P(x_i|l)))$ )

4. 比较后验概率, 选择值更大的类别

5. 若后验相等: 用最小特征值打破平局

对数概率技巧: 由于多个小于1的概率相乘会下溢 (变成0), 所以对概率取对数, 把乘法变加法

#### [Exam 2020-2021 Final] Q3 (20分)

4个样本, 特征 $x_1$ - $x_4$ 取值{0,1}, 标签 $l=0$ 或1。预测未知实例 $x=[1,0,1,1]$ 。

Answer: 预测:  $l=1$

Analysis: 不平滑时:  $P(x_3=1|l=0)=0/2=0 \rightarrow$  整个后验=0。用平滑后:  $P(l=1|x)=0.0703 > P(l=0|x)=0.0117 \rightarrow$  预测 $l=1$

#### [Exam 2022-2023 Final] Q3 (14分)

高尔夫数据。预测: 雨天 + 湿度<65%。

Answer: 预测: YES (打高尔夫)

Analysis:  $P(\text{Yes}|\text{Rainy}, H<65\%)$  正比于  $0.6 * 2/3 = 0.4$ ;  $P(\text{No}|\dots)$  正比于  $0.4 * 1/2 = 0.2$ 。归一化后:  $P(\text{Yes})=2/3 > P(\text{No})=1/3$

#### [Exam 2023-2024 Resit] Q1 (10分)

高尔夫数据。预测: 雨天 + 湿度>65%。

Answer: 预测: NO (平局, 按最小湿度打破)

Analysis: 两者后验均正比于0.2, 平局! NO的湿度75% < YES的湿度80% → 预测NO。

#### [Exam 2025 Sample] Q14 (2分)

拉普拉斯平滑在朴素贝叶斯中的核心作用?

Answer: 修复零概率问题 (Fix the zero-probability issue)

Analysis: 当某特征值在训练集中某类别从未出现时,  $P(x|y)=0$ , 导致整个后验为0。平滑给所有计数+1, 防止此问题。

### 3. K-means 聚类计算

---

#### Lloyd 算法步骤 (Lloyd Algorithm Steps)

1. 随机初始化  $k$  个簇中心 (Initialize  $k$  cluster centers randomly)
2. 将每个点分配给最近的中心 (Assign each point to nearest center)
3. 重新计算中心 = 簇内所有点的坐标均值  
(Recalculate center = mean of all points in cluster)
4. 重复步骤2-3 直到收敛 (中心不再变化)

K-means 保证收敛到局部最优 (LOCAL optimum) , 不保证全局最优

初始中心位置影响最终结果 → K-means++ 改进了初始化方法 (使初始中心更分散)

#### [Exam 2020-2021 Final] Q2 (10分)

第一次迭代后:  $C1=\{(0,6),(6,0)\}$ ,  $C2=\{(2,2),(4,4),(6,6)\}$ ,  $C3=\{(5,5),(7,7)\}$ 。计算新中心。

Answer:  $C1=(3,3)$ ,  $C2=(4,4)$ ,  $C3=(6,6)$

Analysis: 中心 = 坐标均值。C1:  $((0+6)/2, (6+0)/2)=(3,3)$ 。C2:  $((2+4+6)/3, (2+4+6)/3)=(4,4)$ 。C3:  $((5+7)/2, (5+7)/2)=(6,6)$

#### [Exam 2023-2024 Sample] Q19 (14分)

$K=2$ , 初始中心 $Z1=(2,3)$ ,  $Z2=(10,15)$ 。6个点。City Block距离。执行一次迭代。

Answer: 重新分配后:  $Z1$ 簇含A,B;  $Z2$ 簇含C,D,E,F。新中心:  $Z1=(2.5,3.5)$ ,  $Z2=(11.25,12.75)$

Analysis: City

Block距离计算: A到 $Z1=0$ ,到 $Z2=20 \rightarrow$ 归 $Z1$ ; B到 $Z1=2$ ,到 $Z2=18 \rightarrow$ 归 $Z1$ ; C到 $Z1=20$ ,到 $Z2=0 \rightarrow$ 归 $Z2$ , 以此类推。

#### [Exam 2023-2024 Resit] Q2 (18分)

编程题延伸讨论:  $n\_clusters=4$ 对应4个类别——是否保证每类都有一个簇?  $n\_clusters=500$ 对应600个样本——是否过拟合?

Answer: 不保证; 是, 过拟合

Analysis: 相近的类别可能在特征空间中合并到同一个簇。 $n\_clusters=500$ 意味着几乎每样本一个簇——模型记住了训练数据, 无法泛化。

## 4. 感知机证明 (Perceptron Proof)

---

### 感知机模型 (Perceptron Model)

决策函数 (Decision function) :  $f(x) = 1$  if  $w \cdot x + b > 0$ , else 0

单层感知机只能解决线性可分 (linearly separable) 问题

线性可分: 能用一条直线 (或高维超平面) 完全分隔两类的样本

### OR 问题: 线性可分 $\square$ 可以解决

参数示例:  $w=[1,1]$ ,  $b=-0.5$

(0,0):  $-0.5 < 0 \rightarrow$  输出0 (0,1):  $0.5 > 0 \rightarrow$  输出1

(1,0):  $0.5 > 0 \rightarrow$  输出1 (1,1):  $1.5 > 0 \rightarrow$  输出1  $\square$  全部正确!

### AND 问题: 线性可分 $\square$ 可以解决

参数示例:  $w=[1,1]$ ,  $b=-1.5$

(0,0):  $-1.5 < 0 \rightarrow 0$  (0,1):  $-0.5 < 0 \rightarrow 0$

(1,0):  $-0.5 < 0 \rightarrow 0$  (1,1):  $0.5 > 0 \rightarrow 1 \square$  全部正确!

### XOR 问题: 非线性可分 $\square$ 无法解决 — 反证法证明

假设存在  $w_1, w_2, b$  使得感知机正确分类 XOR:

输入(0,0) $\rightarrow$ 输出0:  $b \leq 0 \dots (1)$

输入(0,1) $\rightarrow$ 输出1:  $w_2 + b > 0 \dots (2)$

输入(1,0) $\rightarrow$ 输出1:  $w_1 + b > 0 \dots (3)$

输入(1,1) $\rightarrow$ 输出0:  $w_1 + w_2 + b \leq 0 \dots (4)$

由(2)得:  $w_2 > -b$

由(3)得:  $w_1 > -b$

所以:  $w_1 + w_2 > -2b$

由于  $b \leq 0$ , 则  $-2b \geq 0$ , 因此  $w_1 + w_2 + b > 0$

这与(4)矛盾! 故不存在这样的  $w_1, w_2, b$ . 证毕。QED

XOR的真值表: (0,0) $\rightarrow$ 0, (0,1) $\rightarrow$ 1, (1,0) $\rightarrow$ 1,

(1,1) $\rightarrow$ 0。在二维平面上, 这是'异或'问题, 两类点呈棋盘状交错, 无法用一条直线分开。

### [Exam 2020-2021 Final] Q4 (20分)

感知机能否模拟OR和XOR? 能则给出 $f(x)$ ; 不能则证明。

Answer: OR: 能 ( $w=[1,1], b=-0.5$ ) ; XOR: 不能 (反证法证明)

Analysis: 先画数据点 (4分), 再分别解释/证明 (16分)。XOR证明核心: 推出矛盾。

### [Exam 2020-2021 Resit] Q4(3) (12分)

$class0=\{(0,0),(0.5,0.5),(1,1)\}$ ,  $class1=\{(1,0),(0,1)\}$ 。感知机能否正确分类所有样本?

Answer: 不能 (伪装后的XOR问题)

Analysis: 与XOR相同模式: 对角线上的点为一类, 反对角线上的点为另一类。适用同样的反证法证明。

## 5. 层次聚类 (Hierarchical Clustering) + 树状图

### 凝聚式聚类步骤 (Agglomerative = Bottom-up)

- 1. 开始：每个点各自为一个簇 (Start: each point is its own cluster)
- 2. 计算所有簇两两之间的距离 (Compute all pairwise inter-cluster distances)
- 3. 合并距离最近的两个簇 (Merge the two closest clusters)
- 4. 用联动准则 (linkage) 更新簇间距离  
(Update inter-cluster distances using linkage method)
  - MAX linkage (全联动/Complete)：两簇间最大距离
  - MIN linkage (单联动/Single)：两簇间最小距离
  - AVERAGE linkage (平均联动)：两簇间所有点对距离的平均值
- 5. 重复直至所有点合并为一个簇

MAX linkage (Complete linkage) :  $d(A,B) = \max_{\{a \in A, b \in B\}} \text{distance}(a,b)$

树状图 (Dendrogram)：横轴为样本，纵轴为合并时的距离高度

树状图可以帮你决定最终聚成几簇：在合适的高度'切'树，切过的位置数就是簇的个数。

### [Exam 2023-2024 Final] Q1 (14分)

A=(1,2), B=(2,0), C=(1,0), D=(1,1), E=(4,0)。凝聚式聚类，MAX City Block距离。画树状图。

Answer: 分步合并，详见下方分析

Analysis: City Block距离矩阵：A-D=1, B-C=1, C-D=1 (最小)。先合并B-C，再合并A-D，再与E合并。树状图高度 = 每次合并时的MAX距离。

### 距离矩阵 (City Block)

|   | A | B | C | D | E |
|---|---|---|---|---|---|
| A | 0 | 3 | 2 | 1 | 5 |
| B | 3 | 0 | 1 | 2 | 2 |
| C | 2 | 1 | 0 | 1 | 3 |
| D | 1 | 2 | 1 | 0 | 4 |
| E | 5 | 2 | 3 | 4 | 0 |

## 6. 混淆矩阵 (Confusion Matrix) 计算

---

### 关键公式 Key Formulas

Accuracy (准确率) =  $(TP + TN) / \text{Total}$  即: 正确预测数 / 总数

Precision (精确率) =  $TP / (TP + FP)$  即: 预测为正例中实际为正的的比例

Recall (召回率) =  $TP / (TP + FN)$  即: 实际正例中被找出来的比例

F1 Score =  $2 * \text{Precision} * \text{Recall} / (\text{Precision} + \text{Recall})$  即: 精确率和召回率的调和平均数

TP=True Positive=真阳性 (预测正, 实际正) ; TN=True Negative=真阴性 (预测负, 实际负) ; FP=False Positive=假阳性 (预测正, 实际负) ; FN=False Negative=假阴性 (预测负, 实际正)

### [Exam 2022-2023 Final] Q1 (8分)

n=200。预测NO行: 实际NO=60, 实际YES=5。预测YES行: 实际NO=10, 实际YES=125。求总>1000人数、总<=1000人数、准确率、召回率。

Answer: 实际>1000: 130人; 实际<=1000: 70人; 准确率=92.5%; 召回率=96.15%

Analysis: TP=125, FN=5, TN=60, FP=10。准确率=(125+60)/200=92.5%。召回率=125/(125+5)=96.15%

### [Exam 2022-2023 Resit] Q1 (8分)

n=200。预测NO行: 实际NO=47, 实际YES=30。预测YES行: 实际NO=23, 实际YES=100。求正确数、错误数、准确率、精确率。

Answer: 正确=147; 错误=53; 准确率=73.5%; 精确率=81.3%

Analysis: TP=100, FP=23, TN=47,

FN=30。正确=100+47=147。准确率=147/200=73.5%。精确率=100/(100+23)=81.3%

## 7. Python 编程填空（每年必考！）

□ 这是分值最高的大题类型：每年8-32分！必须熟练掌握。

### 7.1 找奇数（2022-2023 Final Q2）

```
import numpy as np
number = np.random.randint(1, 101, size=(100,)) # [e]=101, [f]=100
def findodd(number):
    odd = []
    for n in number:
        if n % 2 == 1: # 取模运算符[%] 等于运算符[==]
            odd.append(n)
    return odd
```

`randint(1,101)`生成1到100的整数（101是开区间，不包含）。%是取模运算符，`n%2==1`表示n除以2余1，即为奇数。

### 7.2 斐波那契数列（2022-2023 Resit Q2）

```
def Fibonacci(num):
    results = []
    for n in range(num): # [e] = num（循环num次）
        if n < 2:
            results.append(1) # F(0)=1, F(1)=1
        else:
            value = results[n-1] + results[n-2] # [f]=n-1, [g]=n-2
            results.append(value) # [h]=value
    return results
```

斐波那契数列：每个数等于前两个数之和。F(0)=1, F(1)=1, F(2)=2, F(3)=3, F(4)=5, F(5)=8 ...

### 7.3 类内/类间距离比（2023-2024 Final Q2）

```
for i in range(len(features)): # [#001] = len(features)
    for j in range(i+1, len(features)): # [#002] = i+1（上三角，避免重复）
        distance = np.linalg.norm(features[i]-features[j]) # [#003]
        if labels[i] == labels[j]: # [#004] = 同类？
            intra_distances.append(distance) # 类内距离
        else:
            inter_distances.append(distance) # [#005] = 类间距离
    ratio = avg_intra / avg_inter # [#006] = 比值
```

比值越大越好：类内距离小 + 类间距离大 = 分类效果好

类内距离（intra-class）= 同类样本间的平均距离；类间距离（inter-class）= 异类样本间的平均距离。ratio大说明类内紧凑、类间分散，分类质量高。

## 7.4 VotingClassifier 集成 (2023-2024 Final Q3)

```
from sklearn.ensemble import VotingClassifier
ensemble = VotingClassifier(
    estimators=[("knn",knn),("svm",svm),("dt",dt)], voting="hard")
ensemble.fit(X_train, y_train) # [#007]=ensemble, [#008]=X_train, [#009]=y_train
score = ensemble.score(X_test, y_test) # [#010]=score, [#011]=X_test, [#012]=y_test
```

其他集成方法: Stacking (元模型)、Bagging (自助采样)、Boosting (提升法如AdaBoost、Gradient Boosting)

硬投票 (hard voting) : 各分类器直接投票, 少数服从多数。软投票 (soft voting) : 各分类器输出概率, 取平均后选最大概率类别。

## 7.5 K-means 聚类 + 准确率评估 (2023-2024 Resit Q2)

```
for n_clusters in num_clusters_range: # [#001]
    kmeans = KMeans(n_clusters=n_clusters, random_state=0) # [#002]=n_clusters
    kmeans.fit(X) # [#003]=fit
    cluster_labels = kmeans.labels_ # [#004]=kmeans.labels_
    new_labels = np.empty_like(labels) # [#005]=labels
    for cl in np.unique(cluster_labels): # [#006]=cluster_labels
        mask = (cluster_labels == cl) # [#007]
        most_common = stats.mode(labels[mask])[0][0]
        new_labels[mask] = most_common # [#008]=most_common_label
    acc = accuracy_score(labels, new_labels) # [#009]=accuracy
    print(f"n_clusters={n_clusters}, accuracy={acc*100:.3f}%")
```

## 7.6 SVM 交叉验证选最佳C (2023-2024 Resit Q3, 18分)

```
from sklearn.svm import SVC
from sklearn.model_selection import cross_val_score
C_candidates = [0.1, 0.5, 0.7]
best_C, best_score = None, -1
for C in C_candidates:
    svm = SVC(C=C, kernel="rbf", random_state=0)
    cv_scores = cross_val_score(svm, X, y, cv=5)
    if cv_scores.mean() > best_score:
        best_score = cv_scores.mean()
        best_C = C
```

SVM的C参数: 正则化强度的, C越小正则化越强 (更松), C越大正则化越弱 (更紧, 试图正确分类所有训练样本)。过大则过拟合。

## 7.7 kNN 交叉验证选最佳k (2023-2024 Sample Q20, 32分)

```
from sklearn.neighbors import KNeighborsClassifier
from sklearn.model_selection import cross_val_score, KFold
accuracies = [] # [#001] = [] (初始化空列表)
for k in range(5,16): # [#002] = range(5,16) 即k=5,6,...,15
    knn = KNeighborsClassifier(n_neighbors=k) # [#003] = k
```

```
kf = KFold(n_splits=5, shuffle=True, random_state=42) # [#004]=kf
acc_scores = cross_val_score(knn, X, y, cv=kf, scoring="accuracy")
accuracies.append(acc_scores.mean()) # [#005]=acc_scores.mean()
k_best = list(range(5,16))[accuracies.index(max(accuracies))] # [#006]
plt.plot(range(5,16), accuracies, marker="o") # [#007],[#008]
plt.xticks(range(5,16)) # [#009]=range(5,16)
plt.show() # [#010]=show()
```

## 8. 简单线性回归 (Simple Linear Regression) (2025年新增)

### 最小二乘法 (Least Squares Method)

|                                                                                       |                                                 |
|---------------------------------------------------------------------------------------|-------------------------------------------------|
| 模型 (Model) :                                                                          | $y_{\text{hat}} = b_0 + b_1 * x$                |
| 斜率 (Slope) :                                                                          | $b_1 = S_{xy} / S_{xx}$                         |
| 其中 $S_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y})$ , $S_{xx} = \sum (x_i - \bar{x})^2$ |                                                 |
| 截距 (Intercept) :                                                                      | $b_0 = \bar{y} - b_1 * \bar{x}$                 |
| 残差 (Residual) :                                                                       | $e_i = y_i - y_{\text{hat}}$ (残差为正 → 实际值 > 预测值) |

最小二乘法: 找到一条直线, 使所有样本到直线的垂直距离 (残差) 的平方和最小。b1是直线的斜率, b0是直线与y轴的交点。

### [Exam 2025 Sample] Q29 (8分)

|                                                                                                                                                                           |
|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 6名学生: 学习时长x和考试分数y。计算b0、b1。写出回归线。用x=7预测y。                                                                                                                                  |
| Answer: 先计算 $\bar{x}$ 、 $\bar{y}$ , 再算 $S_{xy}$ 和 $S_{xx}$ , 最后 $b_1 = S_{xy} / S_{xx}$ , $b_0 = \bar{y} - b_1 * \bar{x}$                                                 |
| Analysis: 步骤1: $\bar{x} = (2+3+4+5+6+8)/6 = 4.67$ , $\bar{y} = (55+60+62+68+72+78)/6 = 65.83$ 。步骤2: 计算 $S_{xy}$ 和 $S_{xx}$ (展示完整计算过程!)。步骤3: 代入x=7到回归线求 $y_{\text{hat}}$ 。 |

## 9. 描述统计学 (Descriptive Statistics) (2025年新增)

### 五数概括 (Five-Number Summary)

|                                            |
|--------------------------------------------|
| 五数: 最小值 (min)、第一四分位数 (Q1, 第25百分位数)、        |
| 中位数 (Median, Q2, 第50百分位数)、                 |
| 第三四分位数 (Q3, 第75百分位数)、最大值 (max)             |
| $IQR \text{ (四分位距)} = Q3 - Q1$             |
| $\text{下界 (Lower fence)} = Q1 - 1.5 * IQR$ |
| $\text{上界 (Upper fence)} = Q3 + 1.5 * IQR$ |
| 离群值 (Outliers): 超出上下界的值                    |

### 直方图 (Histogram)

|                                                                    |
|--------------------------------------------------------------------|
| 等宽分箱 (Equal-width bins): 如10分一箱: 10-20, 20-30, ...                 |
| 需展示: 每箱频数分布 (mass distribution) AND 累积分布 (cumulative distribution) |

### 箱线图 (Box Plot)

|                                       |
|---------------------------------------|
| 箱子从Q1画到Q3, 中位数画一条线, 须从Q1/Q3延伸到上下界内的最值 |
| 上下界之外的点单独画成圆圈 (即为离群值)                 |

### [Exam 2025 Sample] Q31 (15分)

20个考试分数。任务: (1) 画直方图 (等宽10分箱), 展示频数和累积分布; (2) 五数概括, 画箱线图, 用1.5 × IQR规则找离群值; (3) 评价分布, 提出一种评分缩放方案使得20%学生达到70分以上。

Answer:  $Q1 \approx 29, Q2 \approx 38, Q3 \approx 53.5, IQR \approx 24.5, \text{上下界} \approx [-7.75, 90.25]$ 。85是否在界内取决于精确的Q1/Q3计算。

Analysis: 直方图: 10-20(1人), 20-30(4人), 30-40(3人), 40-50(4人), 50-60(3人), 60-70(1人), 70-80(0人), 80-90(1人)。箱线图: 按五数画箱子和须。缩放方案: 例如将分数开方或取对数, 使高分段人数增加。

## 10. GMM 模型选择 (GMM Model Selection) (2025年新增)

### BIC/AIC vs 交叉验证 (Cross-Validation)

|                                                                             |
|-----------------------------------------------------------------------------|
| BIC (贝叶斯信息准则) = $-2 \cdot \log(L) + k \cdot \log(n)$ 其中 $k$ =参数个数, $n$ =样本数 |
| AIC (赤池信息准则) = $-2 \cdot \log(L) + 2 \cdot k$                               |
| BIC/AIC 假设: 数据确实来自高斯混合分布 (Gaussian mixture)                                 |
| 交叉验证: 将数据分成训练集/验证集, 在验证集上评估                                                 |
| 交叉验证 不假设数据分布, 更通用, 但需要更多数据, 计算开销更大                                          |

### [Exam 2025 Sample] Q30 (7分)

|                                                                   |
|-------------------------------------------------------------------|
| 比较BIC/AIC和交叉验证在评估高斯混合模型时的异同。各自用了什么假设?                             |
| Answer: BIC/AIC假设数据来自高斯混合; 交叉验证不做此假设                              |
| Analysis: BIC/AIC: 理论准则, 假设模型族正确。交叉验证: 经验方法, 不假设分布, 但需要足够数据且计算量大。 |

## 11. 3折交叉验证 kNN 手算 (2025年新增)

---

### 手动交叉验证步骤

给定12个样本, 2个特征, 二分类标签 $y$

折1 (测试集) = {1,2,3,4}, 折2 (测试集) = {5,6,7,8}, 折3 (测试集) = {9,10,11,12}

每折操作:

1. 用其他8个样本作为训练集
2. 对每个测试样本, 计算到所有8个训练样本的 City Block 距离
3. 找到1-NN (最近邻)
4. 预测类别 = 最近邻的类别
5. 检查预测是否与实际标签匹配

每折准确率 = 正确预测数 / 4

总体交叉验证准确率 = 三折准确率的平均值

### [Exam 2025 Sample] Q32 (15分)

12个样本, 2个特征, 二分类. 3折交叉验证, 1-NN, City

Block距离. 展示每个预测的最近邻样本ID和距离. 计算每折准确率和总体交叉验证准确率。

**Answer:** 需要对全部12个样本在3个折中分别手动计算距离

Analysis: 样本1(2,1, $y=0$ ): 在折1中作为测试样本时, 训练集为{5..12}。计算到所有8个训练点的距离。找到最小距离 → 1-NN预测。对折2和折3重复此过程。

附录：历年大题一览表

此表覆盖2020-2025年所有INT104期末/补考/样卷中的非选择题大题  
MCQ（选择题）未列入；MCQ考点另见《INT104选择题高频考点》

| 年份      | 题号   | 知识点     | 分值 | 题目描述                        |
|---------|------|---------|----|-----------------------------|
| 2020-21 | Q1   | kNN     | 10 | 3-NN Manhattan 2            |
| 2020-21 | Q2   | K-means | 10 |                             |
| 2020-21 | Q3   |         | 20 | $x=[1,0,1,1]$               |
| 2020-21 | Q4   |         | 20 | OR+XOR                      |
| 2020-21 | Q1   | kNN     | 10 | 3-NN Manhattan 2 CV         |
| 2020-21 | Q2   | K-means | 10 |                             |
| 2020-21 | Q3   |         | 20 | $x=[1,0,1,0]$               |
| 2020-21 | Q4   |         | 20 | AND + XOR                   |
| 2022-23 | S2Q1 |         | 8  |                             |
| 2022-23 | S2Q2 | Python  | 8  | numpy                       |
| 2022-23 | Q3   |         | 14 | + <65%                      |
| 2022-23 | Q4   | kNN     | 10 | k=3 City Block              |
| 2022-23 | Q5   | kNN     | 6  |                             |
| 2022-23 | S2Q1 |         | 8  |                             |
| 2022-23 | S2Q2 | Python  | 8  |                             |
| 2022-23 | Q3   |         | 14 | + >2                        |
| 2022-23 | Q4   | kNN     | 16 | k=1,2,5 k                   |
| 2023-24 | Q1   |         | 14 | +MAX City Block+            |
| 2023-24 | Q2   | Python  | 16 | /                           |
| 2023-24 | Q3   | Python  | 16 | VotingClassifier            |
| 2023-24 | Q1   |         | 10 | + >65%                      |
| 2023-24 | Q2   | Python  | 18 | K-means+                    |
| 2023-24 | Q3   | Python  | 18 | SVM C                       |
| 2023-24 | Q4   | Python  | 18 | K-means random vs k-means++ |
| 2023-24 | Q19  | K-means | 14 | K-means                     |
| 2023-24 | Q20  | Python  | 32 | kNN k                       |
| 2023-24 | Q21  | Python  | 16 |                             |
| 2025-26 | Q29  |         | 8  | b0 b1                       |
| 2025-26 | Q30  | GMM     | 7  | BIC/AIC vs                  |
| 2025-26 | Q31  |         | 15 | + +IQR                      |
| 2025-26 | Q32  | kNN+CV  | 15 | 3 1-NN                      |