

INT104 人工智能

期末复习笔记

知识点系统总结 + 历年真题讲解

整理自 2020-2025 全部试卷及答案

适用：西交利物浦大学 INT104 期末备考

一、机器学习基础概念

监督学习：有标签数据，用于分类或回归任务。

无监督学习：无标签数据，用于聚类、降维等任务。

半监督学习：部分有标签、部分无标签。

过拟合 (Overfitting)：模型在训练集上误差低，在测试集上误差高。

欠拟合 (Underfitting)：模型在训练集和测试集上误差都很高。

解决方法：增加数据、正则化、降低模型复杂度。

交叉验证 (Cross-Validation)：将数据分为 k 份，轮流用其中 $k-1$ 份训练，

剩余 1 份测试，重复 k 次，取平均性能。

注意：交叉验证不能保证在独立测试集上提升性能。

特征缩放 (Feature Scaling)：将不同量纲的特征统一到相似尺度，

防止某些特征主导距离计算（如 kNN、SVM、K-means）。

常用方法：标准化 (z-score)、归一化 (min-max)。

超参数 (Hyper-parameter)：人为设定的参数，如 kNN 的 k 值、

SVM 的 C 值、K-means 的簇数 k 。

模型参数：通过训练学习得到的参数，如线性回归的系数。

[2025 Sample] Q1 (2分)

Which correctly distinguishes a statistic from a parameter?

Answer: B. Statistic describes sample, parameter describes population

Analysis: 统计量是样本的描述（如样本均值 $\bar{x}$ ），参数是总体的描述（如总体均值 μ ）。

[2025 Sample] Q4 (2分)

Which is NOT required for CLT?

Answer: B. Population must be normally distributed

Analysis:

中心极限定理不要求总体服从正态分布；只要样本独立同分布且样本量足够大，样本均值的抽样分布就近似正态分布。

[2025 Sample] Q19 (2分)

Fail to reject H_0 if p-value is ____ alpha.

Answer: A. greater than

Analysis: $p\text{-value} > \alpha$ 则不拒绝原假设； $p\text{-value} \leq \alpha$ 则拒绝原假设。

二、K近邻算法 (kNN)

核心思想：计算测试点到所有训练点的距离，选择距离最近的 k 个邻居，
通过投票（分类）或平均（回归）决定预测结果。

距离度量

欧氏距离 (Euclidean) : $d = \sqrt{\sum (x_i - y_i)^2}$

City Block (曼哈顿) 距离: $d = \sum |x_i - y_i|$

欧氏距离 = 直线距离; City Block距离 = 沿坐标轴走的距离 (像城市街区一样)。

k 值选择

k 太小 -> 对噪声敏感, 易过拟合

k 太大 -> 决策边界模糊, 易欠拟合

最佳 k 值通过交叉验证 (Cross-Validation) 确定

特征加权与平局处理

特征加权: 如果某些特征更重要, 可以在距离计算中对其差值乘以权重。

平局处理: 当多个类别的投票数相同时, 用距离最小的样本所属类别打破平局。

[2022-2023 Final] Q4 (10分)

$k=3$, City Block 距离, 预测 (晴天, 65%, 3.0m/s) 的高尔夫偏好。

Answer: 预测 NO (不打高尔夫)

Analysis: 3个最近邻全部预测 NO。距离相同时按最小湿度打破平局。

[2025 Sample] Q12 (2分)

Most commonly used distance metric in kNN?

Answer: C. Euclidean

Analysis: kNN 最常用欧氏距离。

[2025 Sample] Q32 (15分)

3-fold CV with city-block, 1-NN.

Answer: 逐个计算距离, 取平均准确率

Analysis: 3折CV: 每次用2个fold训练, 1个fold测试; 用City Block距离找1-NN; 最终CV准确率 = 三折准确率的平均值。

三、朴素贝叶斯 (Naive Bayes)

贝叶斯定理: $P(A|B) = P(B|A) * P(A) / P(B)$

分类: $P(\text{class}|\text{data})$ 正比于 $P(\text{class}) * \text{Product } P(\text{feature}_i|\text{class})$

"朴素"假设: 给定类别后, 所有特征之间条件独立。

即: $P(x_1, x_2, \dots, x_n | \text{class}) = P(x_1|\text{class}) * P(x_2|\text{class}) * \dots * P(x_n|\text{class})$

拉普拉斯平滑 (Laplacian Smoothing)

$P(x|\text{class}) = (\text{count}(x \text{ in class}) + 1) / (\text{total in class} + \text{num_categories})$

作用: 解决零概率问题 (当某个特征值在训练集中未出现时, 条件概率为零会导致整个后验为零)。

必须使用拉普拉斯平滑! 不用平滑时零计数会导致整个后验概率为零!

分类过程

1. 计算各类的先验概率 $P(\text{class})$
2. 用拉普拉斯平滑计算各特征的条件概率 $P(\text{feature}|\text{class})$
3. 对测试样本, 计算各类的后验概率 (取对数避免下溢)
对数概率: $\log(P) = \log(P(\text{class})) + \sum(\log(P(\text{feature}_i|\text{class})))$
4. 选择后验概率最大的类作为预测结果
5. 若后验相等: 用最小特征值 (如最小湿度) 打破平局

[2020-2021 Final] Q3 (20分)

建立朴素贝叶斯分类器, 预测 $x=[1,0,1,1]$ 。

Answer: 预测 $l=1$

Analysis: 不用平滑时 $P(x_3=1|l=0)=0$ 导致后验为零! 用平滑后: $P(l=1|x) = 0.5*0.5*0.5*0.75*0.75 = 0.0703 > P(l=0|x) = 0.0117$

[2022-2023 Final] Q3 (14分)

预测 雨天 + 湿度 < 65% 时的打球偏好。

Answer: 预测 YES (打高尔夫)

Analysis: $P(\text{Yes}|\text{Rainy}, H<65\%)$ 正比于 $0.6 * 2/3 = 0.4 > P(\text{No}|\dots)$ 正比于 $0.4 * 1/2 = 0.2$ 。归一化: $P(\text{Yes})=2/3 > P(\text{No})=1/3$ 。

[2023-2024 Resit] Q1 (10分)

预测 雨天 + 湿度 > 65% 时的偏好。

Answer: 预测 NO (平局打破)

Analysis: 两者后验均正比于0.2, 平局! NO的湿度75% < YES的湿度80% -> 预测NO。

四、感知机 (Perceptron)

感知机模型: $f(x) = 1$ if $w \cdot x + b > 0$, else 0 (阶跃激活函数)

单层感知机只能解决线性可分问题。

线性可分 = 能用一条直线 (或高维超平面) 把两类完全分开

OR 问题: 线性可分 -> 可以

参数示例: $w=[1,1]$, $b=-0.5$

(0,0): $-0.5 < 0 \rightarrow 0$; (0,1): $0.5 > 0 \rightarrow 1$

(1,0): $0.5 > 0 \rightarrow 1$; (1,1): $1.5 > 0 \rightarrow 1$ 全部正确!

AND 问题: 线性可分 -> 可以

参数示例: $w=[1,1]$, $b=-1.5$

(0,0): $-1.5 < 0 \rightarrow 0$; (0,1): $-0.5 < 0 \rightarrow 0$

(1,0): $-0.5 < 0 \rightarrow 0$; (1,1): $0.5 > 0 \rightarrow 1$ 全部正确!

XOR 问题: 非线性可分 -> 不可以 (反证法证明)

XOR 真值表: (0,0) $\rightarrow 0$, (0,1) $\rightarrow 1$, (1,0) $\rightarrow 1$, (1,1) $\rightarrow 0$

不存在任何一条直线能把 (0,0)&(1,1) 与 (0,1)&(1,0) 分开。

反证法证明:

假设存在 w_1, w_2, b 使得感知机正确分类 XOR, 则:

(0,0) $\rightarrow 0$: $b \leq 0 \dots (1)$

(1,1) $\rightarrow 0$: $w_1 + w_2 + b \leq 0 \dots (2)$

(1,0) $\rightarrow 1$: $w_1 + b > 0 \dots (3)$

(0,1) $\rightarrow 1$: $w_2 + b > 0 \dots (4)$

由(3)(4)得: $w_1 > -b, w_2 > -b$, 所以 $w_1 + w_2 > -2b$

若 $b \leq 0$, 则 $-2b \geq 0$, 所以 $w_1 + w_2 + b > 0$, 与(2)矛盾。

结论: 不存在这样的 w_1, w_2, b , 单层感知机无法解决 XOR 问题。

[2020-2021 Final] Q4 (20分)

感知机能否模拟 OR 和 XOR?

Answer: OR: 能 ($w=[1,1], b=-0.5$) ; XOR: 不能 (反证法)

Analysis: XOR证明核心: 推出 $w_1 + w_2 + b$ 既 >0 又 ≤ 0 , 矛盾。

[2020-2021 Resit] Q4(3) (12分)

$class0=\{(0,0),(0.5,0.5),(1,1)\}$, $class1=\{(1,0),(0,1)\}$ 。感知机?

Answer: 不能 (伪装后的XOR)

Analysis: 对角线 vs 反对角线 = XOR模式, 适用同样的反证法。

五、K-means 聚类

核心步骤 (Lloyd算法)

1. 随机初始化 k 个簇中心
2. 分配步骤：将每个样本点分配给距离最近的中心
3. 更新步骤：重新计算每个簇的中心（取簇内所有点的均值）
4. 重复2-3直至中心变化小于阈值或达到最大迭代次数

收敛性：K-means 保证收敛到局部最优解，不保证全局最优。结果受初始中心影响很大。

k 值选择方法

肘部法 (Elbow Method)：绘制 k vs SSE (簇内平方和)，选择拐点

轮廓系数 (Silhouette Score)：值域 $[-1, 1]$ ，越接近1说明聚类效果越好

交叉验证：对于有标签数据，可用聚类准确率选择 k

K-means++ 初始化

改进传统 K-means 的随机初始化，使初始中心尽可能分散，

通常能获得更好的聚类效果和更快的收敛速度。

过拟合问题

当 k 接近样本数时（如 $n_clusters=500$ 对于600个样本），

每个簇只包含很少的点，模型'记住'了训练数据，泛化能力差，属于过拟合。

[2020-2021 Final] Q2 (10分)

K-means 第一次迭代后，计算三个簇的中心。 $C1=\{(0,6),(6,0)\}$, $C2=\{(2,2),(4,4),(6,6)\}$, $C3=\{(5,5),(7,7)\}$

Answer: $C1=(3,3)$, $C2=(4,4)$, $C3=(6,6)$

Analysis: 簇中心 = 簇内所有点的坐标均值

[2023-2024 Resit] Q2(a) (18分)

$n_clusters=4$ 对4类数据，是否保证每类至少分配到一个簇？

Answer: 不保证

Analysis: 两类特征接近时可能被合并到同一簇。

[2023-2024 Resit] Q4 (18分)

比较 random vs k-means++ 初始化，用轮廓系数评估。

Answer: k-means++ 通常轮廓系数更高

Analysis: k-means++ 使初始中心更分散，聚类效果更好。

六、层次聚类 (Hierarchical Clustering)

凝聚式 (Bottom-up) 聚类：初始时每个点各自为一个簇，
每次合并最相似 (距离最小) 的两个簇，直到所有点合并为一个簇。

距离联动方式 (Linkage)

Single (单联动)：两个簇中最近的两个点之间的距离 (易形成链式簇)
Complete / MAX (全联动)：两个簇中最远的两个点之间的距离
Average (平均联动)：两个簇中所有点对之间距离的平均值

树状图 (Dendrogram)

可视化层次聚类的合并过程，高度 = 合并时两个簇之间的距离。
可以从树状图中直观地选择切割高度以确定簇数。

与 K-means 的区别

层次聚类不需要预设 k 值；K-means 需要
层次聚类产生层次结构；K-means 产生扁平簇
层次聚类的时间复杂度较高 ($O(n^3)$ 或 $O(n^2)$)，不适合大数据集

[2023-2024 Final] Q1 (14分)

对点 $A(1,2), B(2,0), C(1,0), D(1,1), E(4,0)$ 进行凝聚式聚类，使用 MAX City Block 距离，画树状图。

Answer: 分步合并，详见解析

Analysis: 1. 计算5x5距离矩阵 (City Block = $|x_1 - x_2| + |y_1 - y_2|$)；2. 最小距离=1 (B-C, A-D, C-D)；3. 合并距离最小的一对；4. 更新簇间距离 (MAX联动)；5. 重复直至全部合并。

七、主成分分析 (PCA)

目的：降维。将高维数据投影到低维空间，同时保留数据中的主要方差信息。

步骤

1. 标准化数据（减去均值，除以标准差）
2. 计算协方差矩阵
3. 对协方差矩阵进行特征值分解
4. 选择前 k 个最大特征值对应的特征向量（主成分）
5. 将数据投影到选定的主成分上

主成分性质

主成分是原始特征的线性组合

各主成分之间相互正交 (uncorrelated)

第一个主成分解释的方差最大，后续依次递减

Eigenfaces: 基于 SVD（奇异值分解）的人脸识别方法，不是 NMF、ICA 或 SVM。

[2025 Sample] Q7 (3分)

Which best describes principal components in PCA?

Answer: C. Linear combinations of original features

Analysis: 主成分是原始特征的线性组合，且相互正交。

[2021-2022 Final MCQ] Q6

Which is NOT true about PCA?

Answer: C. PCA components are not always orthogonal

Analysis: PCA 的主成分始终是正交的。

八、支持向量机 (SVM)

核思想：找到一个超平面，使得两类数据点之间的间隔 (margin) 最大化。

硬间隔 SVM (Hard-margin)

目标函数： $\min (1/2) \|w\|^2$ 等价于最大化分类间隔

支持向量： $\alpha_i > 0$ 的样本点，决定决策边界的位置。

$\alpha_i = 0$ 的点构建 SVM 模型没有影响。

软间隔 SVM (Soft-margin)

允许少量样本被错分，用参数 C 控制对错分的惩罚力度。

C 越大 $\rightarrow$ 惩罚越大 $\rightarrow$ 间隔越小 $\rightarrow$ 模型越复杂 (可能过拟合)

C 越小 $\rightarrow$ 惩罚越小 $\rightarrow$ 间隔越大 $\rightarrow$ 模型越简单 (可能欠拟合)

核技巧 (Kernel Trick)

将低维非线性问题映射到高维空间，使其变为线性可分。

线性核： $K(x,y) = x \cdot y$

多项式核： $K(x,y) = (x \cdot y + c)^d$

RF 核 (高斯核)： $K(x,y) = \exp(-\gamma \|x-y\|^2)$

多分类与缺点

SVM 本身是二分类器，处理多分类时转化为多个 one-vs-one 二分类问题。

缺点：对核参数选择敏感；训练时间复杂度高；对缺失数据敏感。

[2025 Sample] Q15 (2分)

Points with $\alpha=0$ in SVM:

Answer: C. Have no effect on building SVM model

Analysis: $\alpha=0$ 的点不是支持向量，对决策边界没有影响。

[2025 Sample] Q16 (2分)

Minimizing $(1/2)\|w\|^2$ in hard-margin SVM is to:

Answer: B. Maximize the margin between two classes

Analysis: 最小化 $\|w\|^2$ 等价于最大化两类之间的间隔。

九、决策树与随机森林

决策树 (Decision Tree)

流程图式树结构，每个内部节点表示一个特征测试，每个分支表示一个测试结果，每个叶节点表示一个类别。

叶节点预测：当叶节点中包含多个类别的样本时，通常用多数投票 (majority vote) 决定最终预测类别。

过浅 -> 欠拟合 (训练和测试误差都高)；过深 -> 过拟合 (训练误差低、测试误差高)。

随机森林 (Random Forest)

多棵决策树的集成 (ensemble)，可用于分类和回归任务。

训练过程：每棵树在自助采样 (bootstrap) 的数据集上训练，且在每次分裂时只考虑随机子集的特征。

预测过程 (分类)：所有树投票，取多数票作为最终结果。

优点：比单一决策树更鲁棒，不容易过拟合。

[2025 Sample] Q20 (2分)

Leaf node with multiple classes uses ____ vote.

Answer: C. Majority

Analysis: 叶节点用多数投票 (majority vote) 决定预测类别。

十、集成学习 (Ensemble Learning)

投票法 (Voting)

硬投票 (Hard Voting)：直接取所有子分类器预测类别的多数票。

软投票 (Soft Voting)：取所有子分类器预测概率的平均值，选最大概率对应的类别。

软投票通常比硬投票效果更好 (推荐使用)。

sklearn 中的 VotingClassifier

estimators 参数：传入 (名称, 分类器) 元组的列表

voting 参数: "hard" 或 "soft"

其他集成方法

Bagging (Bootstrap Aggregating)：在自助采样的子集上训练多个基学习器，取平均/投票。

Boosting (提升法)：串行训练，每棵树关注前一棵树的错误 (如 AdaBoost、Gradient Boosting)。

Stacking (堆叠法)：训练一个元模型 (meta-model) 来学习如何组合基学习器的预测结果。

[2023-2024 Final] Q3 (16分)

填写 VotingClassifier 集成代码的空白，并列举其他两种集成方法。

Answer: [#007]=ensemble, [#008]=X_train, [#009]=y_train, [#010]=score, [#011]=X_test, [#012]=y_test

Analysis: 其他方法: Stacking (元模型) ; Bagging (自助采样) ; Boosting (提升法) 。

十一、高斯混合模型 (GMM)

假设数据来自多个多元高斯分布的加权混合。

每个高斯分量由均值向量 μ 和协方差矩阵 Σ 描述。

协方差矩阵类型

全矩阵 (full) : 特征相关, 且每个特征方差不同

对角矩阵 (diagonal) : 特征不相关, 但每个特征的方差可以不同

球型 (spherical) : 特征不相关, 且所有特征方差相同 (等价于每个簇是一个圆/球)

EM 算法 (Expectation-Maximization)

E步: 根据当前参数, 计算每个样本属于每个高斯分量的后验概率 (责任度)。

M步: 根据责任度, 重新估计每个高斯分量的参数 (均值、协方差、权重)。重复直至收敛。

模型选择

BIC/AIC 信息准则: 在模型复杂度 (分量数) 和拟合优度之间权衡。假设数据来自高斯混合。

交叉验证: 不做分布假设, 更通用但需要更多数据。

[2025 Sample] Q18 (2分)

Diagonal covariance matrix implies:

Answer: C. Uncorrelated, variable variances

Analysis: 对角协方差矩阵 = 特征不相关 + 各特征方差可不同。

[2025 Sample] Q30 (7分)

Compare BIC/AIC and CV for GMM.

Answer: BIC/AIC 假设高斯混合; CV 不假设

Analysis: BIC/AIC: 理论准则, 假设正确模型族。CV: 经验方法, 分布无关。

十二、线性回归 (Linear Regression)

简单线性回归模型: $y_{\text{hat}} = \beta_0 + \beta_1 * x$

其中 β_0 是截距 (intercept) , β_1 是斜率 (slope) 。

最小二乘法 (Least Squares)

最小化残差平方和: $\min \sum (y_i - y_{\text{hat},i})^2$

斜率: $\beta_1 = S_{xy} / S_{xx}$

其中 $S_{xy} = \sum (x_i - x_{\text{bar}})(y_i - y_{\text{bar}})$, $S_{xx} = \sum (x_i - x_{\text{bar}})^2$

截距: $\beta_0 = y_{\text{bar}} - \beta_1 * x_{\text{bar}}$

残差与相关系数

残差: $e_i = y_i - y_{\text{hat},i}$ (实际值 - 预测值)

残差 > 0 -> 实际值大于预测值; 残差 < 0 -> 实际值小于预测值

皮尔逊相关系数 (Pearson r) : 衡量两个变量之间的线性关系强度和方向。

$r=0$ 没有线性关系 (但可能有非线性关系) ; $|r|$ 越接近1线性关系越强。

[2025 Sample] Q10 (2分)

If residual is positive, actual value is ____ predicted value.

Answer: B. Greater than

Analysis: 残差 = 实际值 - 预测值; 残差 >0 则实际值 $>$ 预测值。

[2025 Sample] Q29 (8分)

6个学生的学习时间 x 和考试分数 y , 计算最小二乘估计。

Answer: 计算 S_{xy} , S_{xx} , 然后 $b_1 = S_{xy}/S_{xx}$, $b_0 = y\text{-bar} - b_1 * x\text{-bar}$

Analysis: 步骤: 1.算 $x\text{-bar}$, $y\text{-bar}$; 2.算 S_{xy} 和 S_{xx} ; 3.算 b_1, b_0 ; 4.代入 $x=7$ 预测 y 。

十三、统计学基础（2025年新增重点！）

2025年 Sample 题新增大量统计学内容，是考试扩展的新趋势，务必重点准备！

正态分布（Normal / Gaussian Distribution）

连续型概率分布，对称、钟形曲线，均值=中位数=众数

不是'固定方差为1'——只有标准正态分布的方差才是1

中心极限定理（Central Limit Theorem）

独立同分布（i.i.d.）的大样本，其样本均值的抽样分布近似服从正态分布。

不要求总体服从正态分布（这是 CLT 的强大之处）

要求样本量足够大（通常 $n > 30$ ），样本独立且同分布

Z 分布 vs t 分布

Z 分布：大样本（ $n \geq 30$ ）或总体标准差 σ 已知时使用

t 分布：小样本（ $n < 30$ ）且总体标准差 σ 未知时使用；自由度 $df = n - 1$

t 分布的尾部比 Z 分布更厚，用于小样本时提供更保守的置信区间

置信区间（Confidence Interval）

用于估计总体参数的范围。如'95%置信区间为[a,b]'意味着：如果重复抽样多次，有95%的区间会包含真实的总体参数。

假设检验（Hypothesis Testing）

原假设 H_0 ：我们要检验的'无效果'假设

备择假设 H_1 ：我们要证明的假设

p值：在 H_0 成立条件下，观测到当前数据（或更极端数据）的概率

决策规则：p值 $> \alpha \rightarrow$ 不拒绝 H_0 ；p值 $\leq \alpha \rightarrow$ 拒绝 H_0

Z-score

$$Z = (x - \mu) / \sigma$$

用于将原始分数标准化，依赖于总体均值和总体标准差。

抽样偏差

自愿响应抽样（Voluntary Response Sampling）：容易有偏差

随机抽样（Random Sampling）：无偏差

分层抽样（Stratified Sampling）：无偏差

[2025 Sample] Q3 (2分)

Key characteristic of normal distribution?

Answer: C. Continuous and symmetric

Analysis: 正态分布是连续的、对称的钟形分布。方差不一定是1。

[2025 Sample] Q17 (2分)

Z-score depends on raw score, population ____ and SD.

Answer: A. Mean

Analysis: $Z = (x - \mu)/\sigma$, 依赖总体均值。

十四、概率与信息论

熵 (Entropy)

$$H = - \sum p_i * \log_2(p_i)$$

衡量随机变量的不确定性。等概率时熵最大；确定事件的熵=0。

4个等概率事件的熵 = $\log_2(4) = 2$ bits

似然函数 (Likelihood Function)

给定模型参数 θ 时，观测到当前数据 D 的概率： $L(\theta) = P(D|\theta)$

似然不是概率分布（对 θ 的积分不一定为1）。

MLE vs MAP

MLE（最大似然估计）：选择使似然函数 $L(\theta)$ 最大的参数 θ （不使用先验）

MAP（最大后验估计）：选择使后验概率 $P(\theta|D)$ 正比于 $L(\theta) * P(\theta)$ 最大的参数 θ （使用先验）

当先验为均匀分布时，MAP 等价于 MLE

抛硬币似然示例

观测：3次正面、2次反面。似然函数 $L(P(H)) = P(H)^3 * (1-P(H))^2$

[2021-2022 Final MCQ] Q10

Entropy of $P1=P2=P3=P4=0.25$ (base=2):

Answer: B. 2 bits

Analysis: 熵 = $-4 * (0.25 * \log_2(0.25)) = -4 * (0.25 * (-2)) = 2$ bits。

[2025 Sample] Q6 (2分)

Coin: 3 heads, 2 tails. Likelihood?

Answer: B. $P(H)^3 * (1-P(H))^2$

Analysis: 似然 = $P(\text{数据}|\text{参数}) = P(H)^3 * (1-P(H))^2$

[2025 Sample] Q7 (2分)

Core difference between MLE and MAP?

Answer: B. MAP uses prior; MLE does not

Analysis: MLE 不使用先验；MAP 使用先验（MAP 正比于 似然 * 先验）。

十五、分类评估指标

混淆矩阵 (Confusion Matrix)

TP (True Positive) : 实际为正, 预测为正

FP (False Positive) : 实际为负, 预测为正 (第一类错误)

FN (False Negative) : 实际为正, 预测为负 (第二类错误)

TN (True Negative) : 实际为负, 预测为负

评估指标公式

准确率 Accuracy = $(TP + TN) / (TP + TN + FP + FN)$

类别不平衡时, 准确率不可靠 (如99%是负类, 全预测负类也有99%准确率)。

精确率 Precision = $TP / (TP + FP)$

预测为正的样本中, 实际为正的的比例 ('预测准不准')。

召回率 Recall = $TP / (TP + FN)$

实际为正的样本中, 被正确预测为正的的比例 ('找得全不全')。

F1 分数 = $2 * (Precision * Recall) / (Precision + Recall)$

F1 越高说明模型在精确率和召回率之间取得了更好的平衡。

AUC-ROC

ROC 曲线: 以 FPR (假正率) 为横轴, TPR (真正率=Recall) 为纵轴

AUC: ROC 曲线下的面积, 值域 [0, 1]。随机分类器 AUC=0.5; 完美分类器 AUC=1

[2025 Sample] Q21 (2分)

F1-score is harmonic mean of?

Answer: B. Precision and Recall

Analysis: F1是精确率和召回率的调和平均。

[2025 Sample] Q22 (2分)

Random classifier AUC?

Answer: C. 0.5

Analysis: 完全随机的二分类器 AUC=0.5。

十六、Python 编程必考 (8-32分, 每年必考!)

Python 填空题/编程题是高频高分题型, 务必熟练掌握 sklearn 各模块的 API!

重点 sklearn 模块

分类器: KNeighborsClassifier, SVC, DecisionTreeClassifier

聚类: KMeans (n_clusters, random_state, fit, labels_)

模型选择: train_test_split, cross_val_score, KFold

集成: VotingClassifier (estimators, voting="hard"/"soft")

评估: accuracy_score, silhouette_score

数据生成: make_blobs (生成聚类数据)

重点 NumPy 操作

np.mean(): 计算均值

np.linalg.norm(): 计算向量/矩阵范数 (欧氏距离)

np.unique(): 返回排序后的唯一值

np.empty_like(): 创建与输入数组形状相同的未初始化数组

Python 基础

Fibonacci 数列: 每个数是前两个数之和

列表 append(): 在列表末尾添加元素

range(): 生成整数序列

取模运算 %: 判断奇偶性 ($n \% 2 == 1$ 为奇数)

[2022-2023 Final] Q2 (8分)

找出1-100中的奇数, 代码填空。

Answer: [e]=101, [f]=100, [g]=%, [h]==

Analysis: randint(1,101)生成1到100的整数 (101是exclusive上界) ; $n \% 2 == 1$ 判断奇数。

[2023-2024 Final] Q2 (16分)

类内/类间距离比代码填空。

Answer: [#001]=len(features), [#003]=features[i]-features[j], [#004]=labels[i]==labels[j],
[#006]=avg_intra/avg_inter

Analysis: 比值越大越好 (类内距离小、类间距离大 -> 分类效果好)。

[2023-2024 Resit] Q2 (18分)

K-means 聚类代码填空 + 过拟合讨论。

Answer: [#001]=num_clusters_range, [#004]=kmeans.labels_

Analysis: $n_clusters=4$ 不保证每类有簇; $n_clusters=500$ 是过拟合。

[2023-2024 Resit] Q3 (18分)

SVM 最佳C值交叉验证选择。

Answer: 遍历C候选值, `cross_val_score(cv=5)`, 选最高准确率的C

Analysis: `SVC(C=C, kernel='rbf', random_state=0) -> cross_val_score -> 选最佳C`

[2023-2024 Sample] Q20 (32分)

kNN 最佳k值交叉验证选择。

Answer: `[#001]=[], [#002]=range(5,16), [#003]=k, [#004]=kf, [#005]=acc_scores.mean(), [#006]=accuracies, [#007]=k_values, [#008]=accuracies, [#009]=k_values, [#010]=show()`

Analysis: 5折CV选最佳k, 画accuracy vs k图

十七、AI 伦理与安全

联邦学习 (Federated Learning)

在多个本地设备上协同训练模型，无需将原始数据上传到中心服务器，从而保护数据隐私。

数据投毒 (Data Poisoning)

向训练集中注入恶意构造的错误标签样本，以降低模型在推理时的性能。

对抗样本 (Adversarial Examples)

对输入数据添加人眼难以察觉的微小扰动，使训练良好的模型做出错误预测。

AI 的应用领域

感知智能 (Perceptual Intelligence)：语音识别、图像分类、情感检测

认知智能 (Cognitive Intelligence)：推理、规划、决策

创作智能 (Creative Intelligence)：音乐生成、文章写作

[2025 Sample] Q24 (2分)

To protect data privacy while training across multiple devices, use ____ learning.

Answer: C. Federated

Analysis: 联邦学习允许多设备协同训练而不共享原始数据。

[2025 Sample] Q25 (2分)

Injecting maliciously crafted mislabeled samples into training dataset is called:

Answer: A. Data poisoning

Analysis: 数据投毒=注入恶意错误标签样本降低模型性能。

附录：重要公式速查

■■■■■	■■■
■■■■■	$d = \sqrt{\text{Sum} (x_i - y_i)^2}$
City Block■■■	$d = \text{Sum} x_i - y_i $
■■■■■	$P(A B) = P(B A) * P(A) / P(B)$
■■■■■■■■■■	$P(x y) = (\text{count}+1) / (\text{total} + \text{num_categories})$
■■■■	$\text{Accuracy} = (\text{TP}+\text{TN}) / \text{Total}$
■■■■	$\text{Precision} = \text{TP} / (\text{TP}+\text{FP})$
■■■■	$\text{Recall} = \text{TP} / (\text{TP}+\text{FN})$
F1■■■	$F1 = 2 * P * R / (P+R)$
■■■■■■■■■■	$\text{beta}_{1} = S_{xy} / S_{xx}$
■■■■■■■■■■	$\text{beta}_{0} = \bar{y} - \text{beta}_{1} * \bar{x}$
■■■	$e_i = y_i - \hat{y}_{i}$
■	$H = -\text{Sum} p_i * \log_2(p_i)$
Z-score	$Z = (x - \mu) / \sigma$
■■■■■	$s = (b-a) / \max(a,b)$
SVM■■■	$\min (1/2) * w ^2 \text{ s.t. } y_i(w \cdot x_i + b) \geq 1$
kNN■■■	■k■■■■■■■■■■

祝希扬考试顺利！