

INT104 Artificial Intelligence

全讲义笔记(Lecture 1-12 + AI Application)

基于课件PDF逐页整理,以考试复习为导向

2025-2026 学年第二学期

Lecture 1 - AI Systems (Overview)

AI 系统工作流程

- Formulate Problem → 定义问题、设定目标
- Collect Data → 收集、清洗、预处理数据
- Feature Extraction → 从原始数据中提取有信息量的特征
- Machine Learning → 训练模型、调参、验证
- System Deployed → 部署、监控、维护

AI 智能层级

层级	说明	典型应用
Computation Intelligence	特征 → 统一标签	分类、异常检测
Perception Intelligence	特征 → 多个非统一标签	情绪检测
Creative Intelligence	生成新内容	AIGC
Universal Intelligence	假设能学任何人类智力任务	AGI

AI 系统面临的挑战

- Insufficient data 数据不足
- Nonrepresentative training data 训练数据不具代表性
- Poor data quality 数据质量差
- Irrelevant features 无关特征
- Overfitting 过拟合 / Underfitting 欠拟合
- Data mismatch (domain) 数据域不匹配

AI 两代发展

- 第一代(符号主义):模拟逻辑推理,知识驱动(专家系统、知识图谱),代表:IBM DeepBlue
- 第二代(连接主义):智能从互联单元中涌现,数据驱动(神经网络、LLM),代表:AlphaGo

Lecture 2 - Data and Statistics

数据类型

- Quantitative vs Categorical:数值型 vs 类别型
- Discrete vs Continuous:离散 vs 连续

测量层级 (Levels of Measurement)

Nominal → Ordinal → Interval → Ratio

实验设计关键原则

- Replication - 重复实验
- Blindness - 盲法(单盲/双盲)
- Randomness - 随机化

抽样方法

方法	说明
Convenience Sampling	方便抽样(非随机,易偏)
Systematic Sampling	系统抽样(等间隔)
Stratified Sampling	分层抽样(层内同质,层间异质)
Cluster Sampling	整群抽样(群内异质,群间同质)

高级实验设计

- Completely Randomised Design - 完全随机设计
- Randomised Block Design - 随机区组设计
- Matched Pairs Design - 配对设计
- Rigorously Controlled Design - 严格对照设计

数据收集的潜在威胁

- Voluntary response sample - 自愿回应偏倚
- Survivorship Bias - 幸存者偏差
- Correlation ≠ Causation - 相关不等于因果

描述数据:五大维度

- Centre - 中心趋势(mean, median, mode)
- Variation - 变异(range, variance, std dev)
- Distribution - 分布形态(Histogram)
- Outliers - 异常值
- Time - 时间变化

Boxplot(箱线图)

- 五数概括:Min, Q1, Median, Q3, Max
- IQR = Q3 - Q1
- 异常值:< Q1 - 1.5×IQR 或 > Q3 + 1.5×IQR

回归

$$\hat{y} = b_0 + b_1x$$

$$b_1 = r \times (S_y/S_x), b_0 = \bar{y} - b_1\bar{x}$$

Lecture 3 - Data Distributions

概率基础

- Probability - 事件发生的可能性
- Conditional Probability $P(A|B)$ - 在 B 发生条件下 A 的概率
- Joint Probability $P(A \cap B)$ - A 和 B 同时发生的概率

概率分布

- PMF (Probability Mass Function) - 离散变量
- CDF (Cumulative Distribution Function) - 累积概率
- PMF 可转换为 CDF

二项分布 (Binomial)

$$P(x) = C(n,x) \cdot p^x \cdot q^{n-x}$$

n =试验次数, x =成功次数, p =单次成功概率, $q=1-p$

泊松分布 (Poisson)

$$P(x) = (\lambda^x \cdot e^{-\lambda}) / x!$$

λ = 区间内事件平均发生次数

正态分布 (Gaussian)

$$f(x) = (1/(\sigma\sqrt{2\pi})) \cdot e^{-(x-\mu)^2/(2\sigma^2)}$$

μ = 均值, σ = 标准差

Z-Score

$$z = (x - \mu) / \sigma$$

标准化为标准正态分布 $N(0,1)$

中心极限定理 (CLT)

- 任意分布的总体, 样本量 $n > 30$ 时
 - 样本均值的抽样分布近似正态
- 样本均值分布: 均值 = μ , 标准差 = $\sigma/\sqrt{n}$

高斯混合模型 (GMM)

$$p(x) = \sum_{i=1}^K \pi_i \cdot N(x | \mu_i, \sigma_i)$$

K =混合分量数, π_i =混合权重($\sum \pi_i=1$)

EM 算法

- E-step: 根据当前参数, 将样本以概率分配到各分量
- M-step: 根据分配结果更新 μ_i, Σ_i, π_i
- 迭代直到收敛

Lecture 4 - Parameter Estimation & Hypothesis Testing

核心概念

- Parameter - 总体描述量(μ, σ)
- Statistic - 样本描述量($\bar{x}, s$)
- Point Estimate - $\bar{x}$ 是 μ 的最佳点估计
- Confidence Level ($1 - \alpha$) - 置信水平(如 95%)

置信区间

CI for proportion: $p \pm z^* \cdot \sqrt{p(1-p)/n}$

CI for mean ($n > 30$): $\bar{x} \pm z^* \cdot s/\sqrt{n}$

CI for mean ($n < 30$): 用 t 分布

假设检验

- H_0 (Null) - 零假设(无差异/无效果)
- H_1/H_a (Alternative) - 备择假设
- $\alpha = P(\text{拒绝 } H_0 \mid H_0 \text{ 为真})$ - 第一类错误概率

检验类型与对应分布

检验参数	对应分布
Mean	Student t(小样本)/ 正态(大样本)
Variance	Chi-Square
Proportion	正态分布

ANOVA

- One-way ANOVA - 检验三组以上均值是否相等
- 前提: 正态、等方差、独立样本
- Two-way ANOVA - 两个因子 + 交互效应

非参数检验

- 不要求正态分布, 适用范围广
- 缺点: 信息浪费、效率较低

Lecture 5 - Counting Theories & Naive Bayes

贝叶斯规则

$$P(C|x) = P(C) \cdot P(x|C) / P(x)$$

- Prior $P(C)$ - 先验概率
- Likelihood $P(x|C)$ - 似然
- Posterior $P(C|x)$ - 后验概率
- Evidence $P(x)$ - 观测(同数据集为常数)

MLE (Maximum Likelihood Estimation)

$$L = P(D|\Theta) = \prod P(x|\Theta)$$

$$LL = \sum \log P(x|\Theta)$$

- 频率学派:选使似然最大的参数

Occam's Razor (Size Principle)

- 模型偏好与数据一致的最简假设
- 例: $D = \{16, 8, 2, 64\}$, "2的幂"比"偶数"似然更高

似然与熵

- 自似然平均 = 负熵: $-\sum p_i \log p_i$
- 交叉熵: $-\sum p_i \log q_i$
- KL 散度 = 交叉熵 - 熵 = $\sum p_i \log(p_i/q_i)$

拉普拉斯修正 (Laplacian Correction)

$$P(\text{feature}|\text{class}) = (\text{count} + 1) / (\text{class total} + \#\text{possible values})$$

□ 解决 zero-probability issue

朴素贝叶斯分类器

$$\text{argmax}_C P(C|x) \propto \text{argmax}_C P(C) \cdot \prod P(x_i|C)$$

□ 朴素假设:给定类别后,各特征条件独立

MAP vs MLE

- MAP: $\text{argmax}_C P(C) \cdot P(x|C)$ - 考虑先验
- MLE: $\text{argmax}_C P(x|C)$ - 不考虑先验

贝叶斯网络

- DAG 表示特征间依赖
- 联合概率分解为条件概率乘积

Lecture 6 - PCA, Correlation & Regression

PCA (主成分分析)

- 核心:找新轴使方差最大化且相互正交

步骤:标准化 → 协方差矩阵 → 特征分解 → 投影

$$X = W \cdot HT (H \text{ 是基})$$

PCA 用途与局限

用途	局限
降维	仅捕获线性关系
可视化	对尺度敏感(必须标准化)
去噪	主成分可解释性差
消除多重共线性	对异常值敏感

Pearson 相关系数

$$r = [n\sum xy - (\sum x)(\sum y)] / \sqrt{[n\sum x^2 - (\sum x)^2] \cdot [n\sum y^2 - (\sum y)^2]}$$

- $-1 \leq r \leq 1$,对异常值极其敏感
- $r = 0$ 不代表无关系(可能非线性)

□ 高相关 ≠ 因果;低相关 ≠ 无关联

回归

线性: $\hat{y} = b_0 + b_1x, b_1 = r \cdot (S_y/S_x)$

多元: $\hat{y} = b_0 + b_1x_1 + \dots + b_kx_k$

逻辑: $P(Y=1) = 1/(1+e^{-z}), z = \beta_0 + \beta_1x_1 + \dots$

残差分析

$$\text{Residual} = y - \hat{y}$$

- 理想残差图:随机散布,无模式

Lecture 7 - Support Vector Machine

最大间隔分类

决策边界: $w^T x + b = 0$

预测: $\hat{y} = \text{sign}(w^T x + b)$

几何间隔: $\gamma_i = y_i(w^T x_i + b) / \|w\|$

优化: $\min \|w\|^2/2, \text{s.t. } y_i(w^T x_i + b) \geq 1$

Hard Margin vs Soft Margin

	Hard Margin	Soft Margin
特点	所有样本必须正确分类	允许间隔违规
限制	数据必须线性可分	超参数 C 控制容忍度

- C 小 → 更宽容; C 大 → 更严格

核函数

- 多项式核: 无需显式添加多项式特征

高斯 RBF 核: $\phi(x, l) = e^{(-\gamma \|x-l\|^2)}$

- l = landmark, γ 控制影响范围

SVM 回归 (SVR)

- 在街道上包含尽可能多的实例
- 街道宽度由 ϵ 控制

感知器与深度学习

- Perceptron = 线性函数 + 激活函数
- CNN - 空间轴扩展; RNN - 时间轴扩展

Lecture 8 - Non-parametric Learning

非参数模型

- 不假设已知参数形式,模型复杂度随数据增长
- 优点:无需分布假设;缺点:样本复杂度大,对窗口大小敏感

kNN

步骤:算距离 → 选 k 近邻 → 多数投票

- 影响预测:距离度量、特征缩放、k 值、加权/无权、平票处理

决策树 - 分裂度量

Entropy: $H(D) = -\sum p_k \log_2 p_k$

Info Gain: $\text{Gain}(D, x_j) = H(D) - \sum (|D_v|/|D|) \cdot H(D_v)$

Gain Ratio: $\text{GainRatio} = \text{Gain} / IV(a)$

Gini: $\text{Gini}(D) = 1 - \sum p_k^2$

层次聚类 (Agglomerative)

Linkage	定义	特点
Single	最近点对距离	易链状
Complete	最远点对距离	偏好紧凑簇
Average	平均距离	折中

k-means

算法:选 k → 初始化质心 → 分配 → 更新 → 重复直到收敛

□ 质心更新始终用均值,即使分配用 city-block 距离

- 超参数选择:Elbow Method / Silhouette Score

k-means 手算示例(L8 例题)

7个点,k=2,初始质心 (1,1) 和 (5,7),city-block 距离

Iteration 1: Cluster1={A,B,C}, Cluster2={D,E,F,G}

Iteration 2: C 移到 Cluster2

Iteration 3: 分配不变 → 收敛

最终: C1={A(1,1),B(1.5,2)} $\mu_1=(1.25,1.5)$; C2={C,D,E,F,G} $\mu_2=(3.9,5.1)$

Lecture 9 - Performance Evaluation

混淆矩阵

	Predicted +	Predicted -
Actual +	TP	FN
Actual -	FP	TN

核心指标(必背)

指标	公式	含义
Accuracy	$(TP+TN)/n$	整体正确率
Precision	$TP/(TP+FP)$	预测为正中真为真的比例
Recall/Sensitivity/TPR	$TP/(TP+FN)$	真正中被找出的比例
Specificity/TNR	$TN/(TN+FP)$	真负中被正确排除的比例
F1 Score	$2 \cdot P \cdot R / (P + R)$	P 与 R 的调和平均
FPR/Fall-out	$FP/(TN+FP)$	假正率
FNR/Miss Rate	$FN/(TP+FN)$	漏检率

ROC 与 AUC

- ROC 曲线: TPR vs FPR(不同阈值下)
- AUC = 1 完美; AUC = 0.5 随机; AUC > 0.5 优于随机

交叉验证

方法	说明
k-fold CV	数据分 k 份轮流做测试(k=5,10常见)
Leave-one-out	k=n,每次留一个
Bootstrap	有放回抽样

Three-way Data Split

- Training set - 拟合参数
- Validation set - 调参/模型选择
- Test set - 最终评估(评估后不可再调!)

模型选择准则

$$AIC = 2k - 2\ln(L)$$

$$BIC = k \cdot \ln(n) - 2\ln(L)$$

BIC 对复杂度惩罚更重

Lecture 11 - AI Ethics and Future Development

AI 系统问题

- Data Privacy 数据隐私
- Algorithm Bias 算法偏见
- Evaluation Bias 评估偏见
- System Security 系统安全
- Deepfake 虚假媒体
- Power Consumption 能耗问题

联邦学习 (Federated Learning)

- 数据保留在本地,只聚合模型参数
- 问题:本地数据可能不一致(特征定义、质量、分布不同)

各算法的假设(必须理解)

算法	核心假设
GMM	簇可用高斯分布近似
SVM	存在线性可分的特征空间
Naive Bayes	特征条件独立

系统安全攻击

- Perturbation attack - 添加微小噪声使模型误判
- Data poisoning - 向数据集注入恶意数据

小数据学习

- Few-shot / First-shot / Zero-shot learning

未来方向

- Incremental Learning - 增量学习
- Explainable AI (XAI) - 可解释AI(LIME, SHAP)
- EU AI Act 等法规框架
- Ethics-by-Design - 生命周期每个阶段嵌入偏见检查

Lecture 12 - Revision(考试题型示例)

题型 1:k-means 手算(15分)

- 给定数据点和初始质心,用 city-block 距离迭代

题型 2:朴素贝叶斯分类(15分)

- 计算先验和似然,预测新样本,注意 Laplace smoothing

题型 3:混淆矩阵 + 指标(15分)

- 构建 confusion matrix,计算各指标,阈值变化后重算

题型 4:层次聚类手算(15分)

- Single linkage 逐步合并,画树状图

题型 5:似然函数

- 写出 $L(p)$,计算不同 p 值的似然,判断哪个更好

题型 6:相关分析

- 计算 Pearson r ,判断相关 vs 因果

AI Application(补充专题)

特征提取方法

- Haar Features - 边缘/线特征
- HoG (Histogram of Gradients) - 方向梯度直方图
- LBP (Local Binary Patterns) - 局部二值模式
- Spatial Pyramid Matching - 空间金字塔匹配

神经网络

- 单层:感知器(线性函数 + 激活函数)
- 多层:Input → Hidden → Output
- 激活函数:step, sigmoid, ReLU

CNN

- 卷积:局部连接 + 权值共享(5×5 窗口仅 25 参数)
- 池化:Max/Average,增强鲁棒性和平移不变性
- 特征层级:Low-level → Mid-level → High-level

Transformer 与大语言模型

- Attention 机制:建模长程依赖
- 发展:2017 Transformer → 2018 BERT/GPT → 2020 GPT-3 → 2022 ChatGPT → 2024 推理模型

推理模型 (2024+)

- o1, DeepSeek-R1, Kimi-k1.5 - 逐步推理
- DeepSeek:纯 RL 训练推理能力

人脸识别流程

Detection → Keypoint → Alignment → Liveness → Feature Extraction → Comparison → Identity

目标检测

- 传统:HOG/LBP → SVM/Boosting
- Two-stage:Faster R-CNN
- One-stage:YOLO

语音识别

- 声学模型:GMM-HMM / DNN-HMM
- 语言模型:文本语料训练

RAG 与知识图谱

- RAG - 检索增强生成
- Knowledge Graph - 知识图谱

考试关键提示

- 1. ML 公式不提供,必须背:NB、DT(Entropy/Info Gain/Gini/Gain Ratio)、Confusion Matrix、k-means 步骤
- 2. 统计公式会提供:Pearson r、回归公式等--但必须会代入和解释
- 3. 手算题重点:k-means、NB、Hierarchical Clustering、Confusion Matrix、似然函数
- 4. 选择题高频:MLE vs MAP、Over/Underfitting、PCA、CV、SVM 核函数、联邦学习、数据投毒
- 5. 简答题:GMM vs CV、相关 vs 因果、各算法假设与局限